Tech4Aqua – 2. Toplantı: Model Seçimi ve Yöntem Belirleme

Nov 7, 2026 · @afra

Özet

Ana bulgu: Görülmemiş bölgelerde ve gelecek yıllarda modelin bilgisinin neredeyse tamamı klordan geliyor. Erken uyarı açısından asıl önemli olan rutin numunelerde model, yalnız klor sıralamasını geçemiyor.

Hocanın dört sorusunun kısa cevabı:

1. **Rutin numuneler:** 82 pozitifin 57'si (%69,5) soruşturma numunesi. Rutin numunelerde pozitif oranı %6,4. En iyi model burada ROC-AUC 0,78, PR-AUC 0,20 alıyor; alarmların yalnızca %10'u doğru.
2. **Yalnız klor:** Rutin numunelerde yalnız klor sıralaması ROC-AUC 0,85, PR-AUC 0,27 veriyor. Model bundan kötü değil ama daha iyi de değil.
3. **Zaman:** Geçmişle eğitip gelecek yılları test edince, 2025 hariç modelin ROC-AUC değeri 0,61–0,62'ye düşüyor. Aynı yıllarda yalnız klor 0,70–0,78 alıyor.
4. **Gecikmeli yağış:** Son 3 ve 7 günün yağışı modeli iyileştirmiyor, anlamlı biçimde kötüleştiriyor (ROC-AUC −0,026). Pozitiflerden önce yağış daha az, hava daha sıcak.

Model seçimi için öneri: Ana model A seti ile Lojistik Regresyon. MLP, GroupDRO ve CORAL denendi; hiçbiri bu modeli geçmedi. Her sonuç yalnız klor ile birlikte ve rutin numunelerde ayrıca raporlanacak.

Soru 1 – Rutin numunelerde performans

Hocanın hesabı doğrulandı: Pozitiflerin %69,5'i soruşturma numunelerinden geliyor. Rutin numunelerde model belirgin biçimde zayıflıyor.

Grup	Numune	Pozitif	Pozitif oranı	Pozitiflerin payı
Tümü	522	82	%15,7	%100
Rutin	390	25	%6,4	%30,5
Soruşturma	132	57	%43,2	%69,5

A seti ile Lojistik Regresyon, ZAPE gruplu ve arındırılmış 5 katlı CV, 5 tohum ortalaması:

Eğitim	Test	ROC-AUC	PR-AUC	MCC (eğitimde seçilen eşik)	MCC (0,5 eşiği)	Kesinlik	Duyarlılık
Tüm veri	Tümü	0,756	0,348	0,21	0,29	0,26	0,60
Tüm veri	Soruşturma	0,768	0,692	0,40	0,36	0,68	0,61
Tüm veri	Rutin	0,782	0,199	0,12	0,23	0,10	0,57
Yalnız rutin	Rutin	0,827	0,261	0,18	0,26	0,24	0,22

- Rutin numunelerde PR-AUC 0,20, rastgele düzeyin (0,064) yaklaşık 3 katı. Ancak model 10 alarm verdiğinde yalnızca 1'i gerçekten pozitif çıkıyor.
- Model yalnız rutin numunelerle eğitilince sıralama iyileşiyor (ROC-AUC 0,83, PR-AUC 0,26). Soruşturma numuneleri rutin izleme için yanıltıcı örnekler katabiliyor.
- "Model 'olay sonrası mı alınmış' sorusunu öğreniyor mu?" sorusunu da test ettik. Özelliklerle numunenin soruşturma numunesi olup olmadığı tahmin edildi: Hava ve takvim (B seti) ROC-AUC 0,64, A seti 0,60, yalnız klor 0,39. Yani hava ve ay bilgisi bu durumu kısmen ele veriyor; klor ise vermiyor.

Soru 2 – Yalnız klorla kıyas

Rutin numunelerde yalnız klor sıralaması modelden kötü değil. Model yalnızca tüm veride PR-AUC'de küçük bir üstünlük gösteriyor ve bu üstünlük soruşturma numunelerinden geliyor.

Yöntem: Hiç model eğitilmedi. Numuneler serbest klor değerine göre sıralandı (düşük klor = yüksek risk). Eksik klor, modelin yaptığı gibi medyanla dolduruldu. Yasal kural ise "klor ⩽ 0,2 mg/L ise riskli" olarak alındı.

Test	Yöntem	ROC-AUC	PR-AUC	MCC
Tümü	Model (A + LR)	0,759	0,347	0,21–0,29
Tümü	Yalnız klor	0,720	0,281	–
Tümü	Kural: klor ⩽ 0,2	–	–	0,28
Rutin	Model (A + LR)	0,783	0,197	0,12–0,23
Rutin	Yalnız klor	0,848	0,270	–
Rutin	Kural: klor ⩽ 0,2	–	–	0,26

Model ile yalnız klor arasındaki fark, ZAPE düzeyinde eşleştirilmiş bootstrap ile test edildi (2000 tekrar, %95 güven aralığı):

- **Tümü, ROC-AUC:** +0,039 (−0,017 ile +0,119). Anlamlı değil.
- **Tümü, PR-AUC:** +0,066 (+0,004 ile +0,184). Model lehine, sınırda anlamlı.
- **Rutin, ROC-AUC:** −0,065 (−0,160 ile +0,056). Anlamlı değil, klor lehine.
- **Rutin, PR-AUC:** −0,072 (−0,157 ile +0,062). Anlamlı değil, klor lehine.

Uyarı: Klor ölçümü eksik olan 15 numunenin tamamı soruşturma numunesi. Eksik kloru "en riskli" saymak tüm veride ROC-AUC'yi 0,78'e çıkarıyor, ama bu aslında soruşturma bilgisini sızdırmak demek. Bu yüzden kullanılmadı.

Soru 3 – Zamana göre doğrulama

2025 çıkarılınca model gelecek yıllarda çöküyor (ROC-AUC 0,59–0,62) ve yalnız klor sıralamasının (0,70–0,78) gerisinde kalıyor. Modelin geçmişten öğrendiği hava ve ay ağırlıkları geleceğe taşınmıyor.

Kurulan protokoller (eğitim verisi her zaman test verisinden önceki tarihlerden oluşuyor):

- **Genişleyen pencere:** Her test yılı (2015–2025), kendinden önceki tüm yıllarla eğitilen modelle tahmin edildi. Yılların tahminleri birleştirilip tek bir ROC/PR hesaplandı.
- **2020 bölmesi:** 2008–2019 ile eğitim, 2020–2025 ile test.
- İkisi de "görülmemiş ZAPE" kuralıyla da çalıştırıldı: Test yılının ZAPE'leri eğitimden tamamen çıkarıldı.

A seti ile Lojistik Regresyon ve yalnız klor, aynı test numunelerinde (ROC-AUC / PR-AUC):

Protokol	Test	Pozitif	Model	Yalnız klor
Genişleyen pencere, görülmemiş ZAPE	Tümü	55	0,743 / 0,370	0,763 / 0,365
Genişleyen pencere, görülmemiş ZAPE	2025 hariç	27	0,623 / 0,166	0,730 / 0,253
Genişleyen pencere, görülmemiş ZAPE	Rutin	5	0,782 / 0,098	0,909 / 0,205
Genişleyen pencere	2025 hariç	36	0,613 / 0,209	0,704 / 0,241
2020 bölmesi	Tümü	40	0,783 / 0,441	0,772 / 0,348
2020 bölmesi	2025 hariç	12	0,593 / 0,080	0,784 / 0,168
2020 bölmesi, görülmemiş ZAPE	2025 hariç	12	0,622 / 0,087	0,784 / 0,168

Protokol	Test	Pozitif	Model	Yalnız klor
ZAPE gruplu CV (zaman yok)	2025 hariç	54	0,671 / 0,187	–

Yıl bazında sonuçlar (genişleyen pencere, görülmemiş ZAPE, A + LR):

Test yılı	Numune	Pozitif	ROC-AUC	PR-AUC
2025	38	28	0,96	0,98
2024	66	6	0,57	0,11
2023	26	1	0,48	0,07
2022	29	1	0,36	0,05
2021	26	2	0,62	0,14
2020	36	2	0,74	0,16
2018	30	4	0,69	0,32
2017	35	11	0,74	0,73

- Birleşik sonucu 2025 belirliyor: O yıl 38 numunenin 28'i pozitif ve hepsi soruşturma numunesi.
- 2020–2023 arasında her yıl yalnızca 1–2 pozitif var. Bu yılların tek başına değerleri güvenilir değil; yalnızca birleşik sonuç yorumlanmalı.
- Ağaç modelleri zamansal testte rastgele düzeye yaklaşıyor (görülmemiş ZAPE ile RF 0,51, LightGBM 0,61). Döneme özgü örüntüleri ezberliyorlar.
- 2008–2014 arasında yalnızca 7 ZAPE'den numune var. Bu yüzden 2015 test yılı, görülmemiş ZAPE kuralıyla eğitimde 5'ten az ZAPE kaldığı için atlandı.

Soru 4 – Gecikmeli yağış

Son 3 ve 7 günün yağışı modeli iyileştirmiyor; tersine anlamlı biçimde kötüleştiriyor. Pozitif numunelerden önceki günlerde yağış daha az, hava daha sıcak.

Neden dış veri gerekti? Veri setinde hava durumu yalnızca numune günü için var. Veri setindeki `PRECIP_LAG1_REGIONAL` sütunu "bir önceki gün" anlamına gelmiyor. Bu sütun, aynı bölgedeki bir önceki numunenin gününü gösteriyor ve bu tarih haftalar öncesi olabilir. Ara rapordaki "gecikmeli hava özellikleri gürültü ekliyor" bulgusunun bir nedeni bu.

Veri: Open-Meteo Historical Weather API (ERA5 tabanlı). Chaves, Montalegre ve Boticas için 2007-12-01 ile 2025-12-31 arası günlük yağış ve sıcaklık kullanıldı. Bu veri, veri setindeki numune günü havasıyla uyumlu: sıcaklıkta r = 0,96, yağışta r = 0,87.

Özellikler: Son 3, 7 ve 14 günün toplam yağışı; son 7 gündeki yağışlı (≥ 1 mm) gün sayısı; son yağışlı günden bu yana geçen gün; son 7 günün ortalama sıcaklığı. Sızıntı olmaması için numune günü hesaba katılmadı (yalnızca D-1 ile D-k arası).

Özellik (medyan)	Negatif	Pozitif	Rutin negatif	Rutin pozitif
Son 3 gün yağış (mm)	1,2	0,2	1,2	1,1
Son 7 gün yağış (mm)	9,8	2,2	9,4	4,2
Son 14 gün yağış (mm)	26,0	6,0	22,6	17,9
Son 7 günde yağışlı gün	2	1	2	1
Son 7 gün ort. sıcaklık (°C)	11,7	16,7	12,4	13,2

Lojistik Regresyon'a yağış özellikleri eklemenin etkisi (ZAPE gruplu CV, eşleştirilmiş ZAPE bootstrap, %95 güven aralığı):

Karşılaştırma	Test	ROC-AUC farkı	PR-AUC farkı
A + son 3/7 gün yağış − A	Tümü	−0,026 (−0,048 ile −0,006)	−0,023 (−0,048 ile −0,002)
A + son 3/7 gün yağış − A	Rutin	−0,035 (−0,073 ile +0,006)	−0,006 (−0,039 ile +0,030)
A + tüm gecikmeli özellikler − A	Tümü	−0,052 (−0,085 ile −0,022)	−0,049 (−0,099 ile −0,019)
B + son 3/7 gün yağış − B	Tümü	−0,028 (−0,052 ile −0,008)	−0,012 (−0,030 ile +0,010)

- Yalnız gecikmeli hava özellikleriyle kurulan model zamansal testte rastgele düzeyde (ROC-AUC 0,51). Yağışın taşıdığı sinyal, mevsim bilgisinin bir tekrarı gibi davranıyor.
- **Olası yorum:** Bu ZAPE'ler arıtılmış ve klorlanmış dağıtım şebekeleri. Kirlenmede yağışla gelen akıştan çok, sıcak ve kuru dönemlerde dezenfeksiyonun zayıflaması etkili görünüyor. Ham su kaynaklarında durum farklı olabilir; veri setinde ham su ölçümü yok.

MCC neden düşük, nasıl yükseltilebilir?

MCC'nin düşük kalmasının üç nedeni var: pozitiflerin nadir olması, girdilerdeki bilginin sınırlı olması ve eşik seçiminin kararsız olması. Bunlardan yalnızca üçüncüsü modelleme tarafında çözülebilir.

1. **Pozitifler nadir.** Rutin numunelerde pozitif oranı %6,4. Bu oranda iyi bir sıralama bile düşük kesinliğe yol açıyor: model 10 alarm verdiğinde yalnızca 1'i doğru çıkıyor. MCC hem kesinliği hem duyarlılığı cezalandırdığı için bu durumda doğal olarak düşük kalıyor.
2. **Bilgi sınırlı.** Aynı numunenin klor değeri dışında güçlü bir öngörücü yok. Yalnız klora dayalı yasal kural (klor ⩽ 0,2 mg/L) bile MCC 0,26–0,28 veriyor; modeller de aynı düzeyde. Hava, ay ve gecikmeli yağış bu tavanı yükseltmiyor.
3. **Eşik kararsız.** Ara rapordaki MCC değerleri (0,25–0,29) sabit 0,5 eşiğiyle hesaplanmıştı. Eşik yalnızca eğitim verisi içinde, iç CV ile seçildiğinde MCC 0,21'e düşüyor. Seçilen eşik katlar arasında belirgin biçimde oynuyor (standart sapma yaklaşık 0,11). 82 pozitif, eşiği güvenilir biçimde belirlemeye yetmiyor.

MCC'yi yükseltmek için seçenekler:

- **Yeni bilgi eklemek (en etkili yol):** Şebeke bilgisi (boru yaşı ve uzunluğu, depo ve hazne verisi), arıtma tesisi çıkışındaki klor, bulanıklık ve iletkenlik gibi fiziko-kimyasal ölçümler. Bu veriler veri setinde yok; başka bir kaynaktan temin edilmesi gerekir.
- **Eşiği kararlı hale getirmek:** Eşiği MCC'ye göre değil, işletmenin kabul edebileceği bir alarm oranına (örneğin numunelerin %10'u) ya da hedef duyarlılığa göre sabitlemek. Yasal klor sınırını bir referans eşik olarak kullanmak da bir seçenek.
- **Görevi yeniden tanımlamak:** "Bu numune pozitif mi?" yerine "bu ZAPE'yi bu ay öncelikle örnekleyelim mi?" sorusu. Bunun için başarı ölçüsü MCC yerine ilk k sıradaki isabet olur.

Model seçimi: değerlendirilen modeller

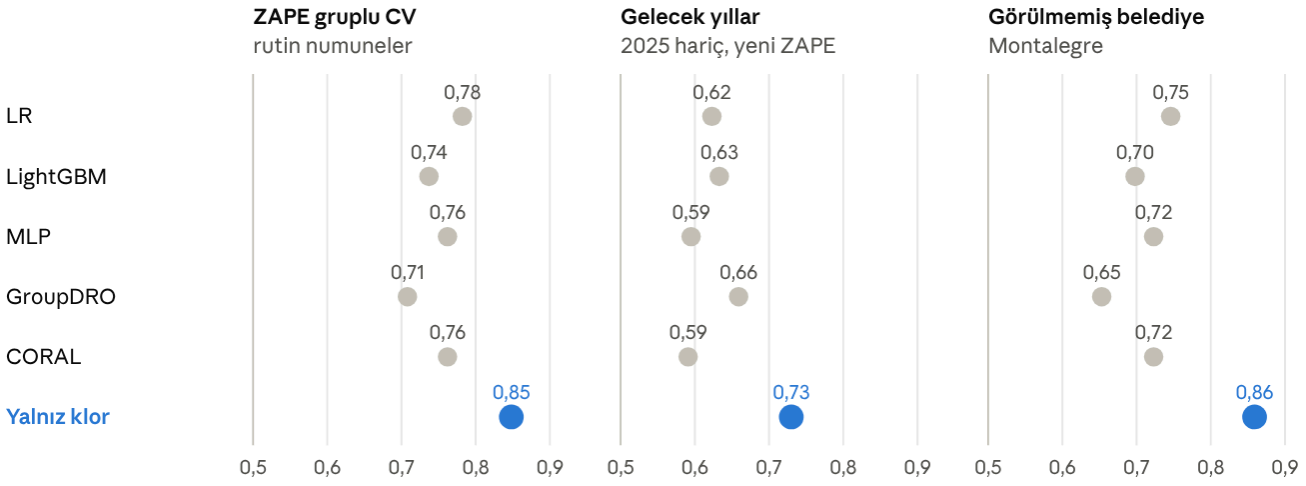
Önerilen ana model A seti ile Lojistik Regresyon. Denenen beş modelin hiçbiri onu anlamlı biçimde geçmedi. Üç zor senaryonun üçünde de eğitimsiz klor sıralaması bütün modellerin üstünde kaldı.

Model	Türü	Neden denendi?
Lojistik Regresyon (LR)	Klasik, doğrusal	Sade ve yorumlanabilir; küçük veride aşırı öğrenmeye dayanıklı
LightGBM	Klasik, ağaç topluluğu	Doğrusal olmayan ilişkileri yakalayabilir

Model	Türü	Neden denendi?
MLP	Derin öğrenme (2 gizli katman: 32 ve 16 nöron)	Projenin derin öğrenme hedefi için temel ağ
GroupDRO	Alan genelleme (Sagawa vd., 2020)	En kötü belediye-sınıf grubunun kaybını azaltır
CORAL	Alan genelleme (Sun ve Saenko, 2016)	Gizli katman temsilini belediyeler arasında hizalar
Yalnız klor	Referans (eğitim yok)	Her modelin geçmesi gereken alt sınır

Üç zor senaryonun üçünde de yalnız klor bütün modellerin üstünde

ROC-AUC, A özellik seti. Mavi nokta: hiç eğitim yapılmadan klor değerine göre sıralama. 0,5 = rastgele.



results/e05_model_comparison · ZAPE CV 5 tohum, zamansal ve belediye testleri 3 tohum

ZAPE gruplu CV'de, tüm numunelerde her modelin LR'den farkı (eşleştirilmiş ZAPE bootstrap, %95 güven aralığı):

Model	ROC-AUC	PR-AUC	ROC-AUC farkı (LR'ye göre)	PR-AUC farkı (LR'ye göre)
LR	0,756	0,348	–	–
LightGBM	0,736	0,319	−0,012 (−0,056 ile +0,040)	−0,037 (−0,128 ile +0,060)
MLP	0,736	0,320	−0,019 (−0,046 ile +0,006)	−0,031 (−0,068 ile +0,001)
GroupDRO	0,732	0,340	−0,009 (−0,052 ile +0,053)	−0,003 (−0,098 ile +0,085)

Model	ROC-AUC	PR-AUC	ROC-AUC farkı (LR'ye göre)	PR-AUC farkı (LR'ye göre)
CORAL	0,735	0,318	−0,020 (−0,046 ile +0,005)	−0,032 (−0,072 ile −0,001)

- Rutin numunelerde GroupDRO, LR'den anlamlı biçimde kötü (ROC-AUC −0,062; −0,095 ile −0,007).
- Alan genelleme yöntemleri için belediyeler alan olarak kullanıldı. Ancak belediyeler çok dengesiz: 69 ZAPE ve bütün soruşturma numuneleri Chaves'te; Montalegre'de 2, Boticas'ta 1 ZAPE var. Boticas'ta hiç pozitif olmadığı için o belediye test edilemedi. CORAL'ın hizalama cezası bu yüzden modeli MLP'den neredeyse hiç farklılaştırmadı.
- Chaves test edildiğinde GroupDRO öne çıktı (ROC-AUC 0,79; LR 0,78; yalnız klor 0,74). Bu tek bir bölmenin sonucu, genel bir üstünlük sayılmamalı.

Eğitim, doğrulama ve test planı

Her model üç ayrı test protokolüyle değerlendirilecek. Her protokol, gerçek kullanımdaki farklı bir zorluğu sınıyor. Doğrulama (eşik seçimi) her zaman yalnızca eğitim verisinin içinde yapılıyor.

Protokol	Sınadığı soru	Eğitim	Test	Tekrar
ZAPE gruplu, arındırılmış 5 katlı CV	Hiç görülmemiş bir bölgede çalışır mı?	Diğer ZAPE'ler; test ile aynı belediye-günü paylaşan numuneler çıkarılır	Bir katın ZAPE'leri	5 tohum
Genişleyen pencere, görülmemiş ZAPE	Gelecekte, yeni bir bölgede çalışır mı?	Test yılından önceki yıllar, test ZAPE'leri hariç	Bir yıl (2017–2025)	3 tohum
Belediye dışarıda bırakma	Başka bir belediyeye taşınabilir mi?	İki belediye	Üçüncü belediye	3 tohum

Bütün protokollerde ortak kurallar:

- **Eşik seçimi (doğrulama):** Karar eşiği, eğitim verisinin içinde 4 katlı ZAPE gruplu iç CV ile seçiliyor. Test verisi eşik seçiminde hiç kullanılmıyor.
- **Ön işleme:** Eksik değer doldurma ve ölçekleme yalnızca eğitim verisinden öğreniliyor.
- **Hiperparametre araması yapılmıyor.** 82 pozitifle arama yapmak aşırı iyimser sonuç verir. Arama yapılacaksa iç CV'nin içinde yapılmalı.

- **Kod düzeyinde kontrol:** Eğitim ve testte ortak ZAPE ya da ortak belediye-gün bulunursa program hata veriyor. Zamansal bölmede eğitimin son tarihi, testin ilk tarihinden önce olmak zorunda.
- **Raporlama:** Her sonuç tüm numunelerde, rutin numunelerde ve 2025 hariç olarak ayrı ayrı veriliyor. Belirsizlik, ZAPE düzeyinde bootstrap ile %95 güven aralığı olarak gösteriliyor.

Bilinen sınırlar: 2020–2023 yıllarında yıl başına yalnızca 1–2 pozitif var. Boticas'ta hiç pozitif yok. Rutin numunelerin zamansal testinde yalnızca 5–7 pozitif kalıyor. Bu sonuçlar yön gösterir, kesin kanıt sayılmaz.

Başarım metrikleri

Ana metrik PR-AUC olacak. Pozitifler nadir olduğu için ROC-AUC tek başına iyimser bir tablo çiziyor; PR-AUC ise alarmların ne kadarının doğru olduğunu doğrudan yansıtıyor.

Metrik	Rolü	Neden?
PR-AUC	Ana metrik	Nadir pozitiflerde gerçekçi; rastgele düzey pozitif oranına eşit (tümü 0,157, rutin 0,064)
ROC-AUC	Yardımcı	Sıralama kalitesini ölçer; ara raporla karşılaştırma için gerekli
MCC	Karar kalitesi	Hem 0,5 eşiğiyle hem eğitimde seçilen eşikle raporlanacak; aradaki fark eşik kararsızlığını gösterir
Kesinlik ve duyarlılık	Karar kalitesi	İşletme için anlaşılır: "10 alarmın kaçı doğru?", "pozitiflerin kaçını yakalıyoruz?"
Brier skoru	Kalibrasyon	Olasılıkların gerçek riskle ne kadar uyumlu olduğunu ölçer

- Her metrik yalnız klor sıralamasıyla birlikte raporlanacak. Model ancak bu referansı geçtiğinde katkı sağlıyor sayılacak.
- Model karşılaştırmalarında tek bir sayı yerine eşleştirilmiş ZAPE bootstrap farkı ve güven aralığı verilecek.

Kararlar ve sonraki deney planı

Toplantıda onaylanmasını istediğimiz kararlar:

1. Ana model A seti ile Lojistik Regresyon olacak. LightGBM, MLP, GroupDRO ve CORAL karşılaştırma modelleri olarak raporda kalacak.
2. Her sonuç yalnız klor sıralamasıyla birlikte, rutin numunelerde ayrıca ve üç test protokolüyle verilecek.
3. Ana metrik PR-AUC olacak; MCC iki eşikle birlikte raporlanacak.
4. Gecikmeli yağış özellikleri ana modele eklenmeyecek; olumsuz sonuç olarak raporlanacak.

Sonraki deneyler (öncelik sırasıyla):

- [ ] Eşiği sabit bir alarm oranına (örneğin numunelerin %10'u) veya hedef duyarlılığa göre belirlemek ve MCC'nin bu durumda nasıl değiştiğini göstermek.
- [ ] Klor ve sıcaklığın birlikte etkisini (sıcakta klorun hızlı bozunması) yalnız rutin numunelerle test etmek. Bu, klorun önüne geçebilecek tek aday.
- [ ] Görevi "ZAPE-ay önceliklendirmesi" olarak yeniden kurup ilk k sıradaki isabeti ölçmek.
- [ ] Kalibrasyon grafiği ve eşik–kesinlik–duyarlılık eğrilerini çizmek.
- [ ] Ham veri setinde kullanılmayan fiziko-kimyasal ölçüm olup olmadığını yeniden kontrol etmek.

Hocaya sormak istediğimiz sorular:

- Projenin derin öğrenme hedefi için "MLP ve alan genelleme yöntemleri denendi, basit modeli geçmedi" bulgusu yeterli mi? Yoksa bu yönde daha fazla çalışma mı bekleniyor?
- Şebeke (boru, depo) veya arıtma tesisi verisine ulaşma imkanımız var mı?
- Başarı ölçütü olarak "numune pozitif mi?" yerine "hangi ZAPE öncelikle örneklenmeli?" sorusuna geçebilir miyiz?
- İşletme için kabul edilebilir bir alarm oranı var mı (örneğin ayda kaç ek numune)?

Ek: Kod ve tekrar üretilebilirlik

Bu dokümandaki tüm sayılar, GitHub deposundaki `afra-dev` dalında bulunan deneylerle yeniden üretilebilir. Kurulum ve veri yerleştirme adımları README dosyasında anlatılıyor.

Komut	Dokümandaki bölüm	Çıktı klasörü
`python -m experiments.e01_baseline`	Ara rapor sonuçlarının yeniden üretimi	`results/e01_baseline/`
`python -m experiments.e02_routine_and_chlorine`	Soru 1 ve Soru 2	`results/e02_routine_and_chlorine/`
`python -m experiments.e03_temporal`	Soru 3	`results/e03_temporal/`

Komut	Dokümandaki bölüm	Çıktı klasörü
`python -m experiments.e04_weather_lags`	Soru 4	`results/e04_weather_lags/`
`python -m experiments.e05_model_comparison`	Model seçimi	`results/e05_model_comparison/`

Veri kaynakları:

- Tech4Aqua veri seti (Mendeley Data)
- Open-Meteo Historical Weather API